STATISZTIKA I

Mennyiségi sorok

A SOKASÁG LEÍRÁSA

- N elemű sokaság
- Ismérv: Y
- Ismérv-változat: Y_1, Y_2, …, Y_i, … Y_k
  - feltétel: Y szerint homogén sokaság
- A leírás módja függ az ismérv mérési szintjétől
  - névleges skála: osztályozás, megoszlási viszonyszámok számítása, grafikon készítése
  - sorrendi skála: + rangsor készítése
  - mennyiségi ismérv → …

3. MENNYISÉGI SOROK

- Rangsor előállítása (Y*)
  - felsorolás monoton nemcsökkenő sorrendben
- Csoportok: az Y ismérv lehetséges értékeinek részhalmazai, intervallumai
- Elnevezés: gyakorisági sor (gyakorisági eloszlás)

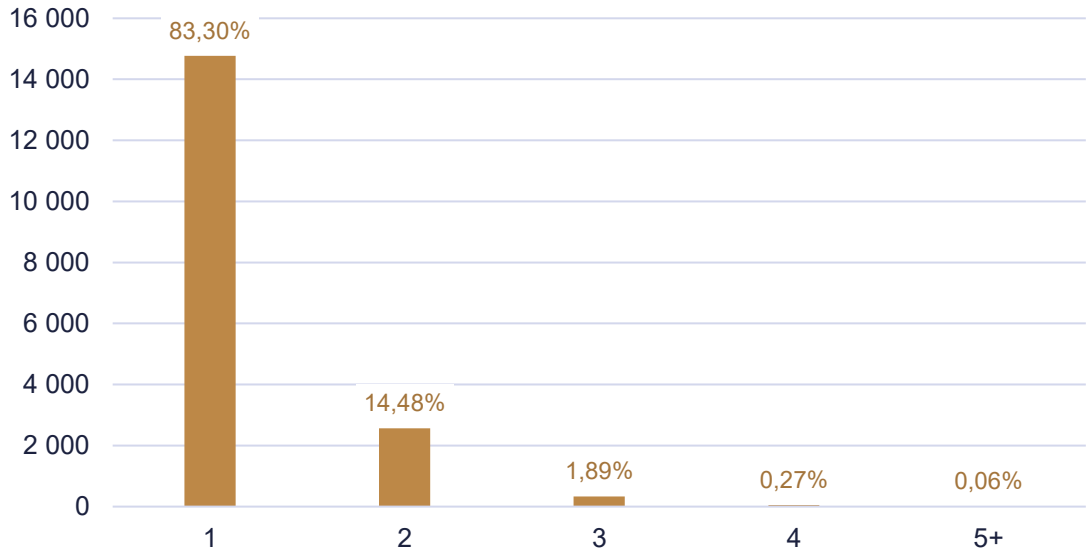
GYAKORISÁGI SOR
Diszkrét ismérv, kevés ismérvváltozat

Ismérvváltozat	Gyakoriság	Rel.gyak.	Kum.gyak.	Kum.r.gyak.
Y_1	f_1	g_1	f'_1	g'_1
Y_2	f_2	g_2	f'_2	g'_2
...	...	...	...	...
Y_i	f_i	g_i	f'_i	g'_i
...	...	...	...	...
Y_k	f_k	g_k	N	1
Összesen	N	1	---	---

- abszolút gyakoriság (f_i)
- relatív gyakoriság: $g_i = \frac{f_i}{N}$
- kumulált abszolút és relatív gyakoriság: $f_i' = \sum_{j=1}^{i} f_j,\ g_i' = \sum_{j=1}^{i} g_j$

Válások száma a férj válásainak száma szerint (2024)

Férj válása	f_i	g_i	f'_i	g'_i
1	14 771	83,30%	14 771	83,3%
2	2 568	14,48%	17 339	97,8%
3	336	1,89%	17 675	99,7%
4	47	0,27%	17 722	99,9%
5+	10	0,06%	17 732	100,0%
Összesen	**17 732**	**100%**	**---**	**---**

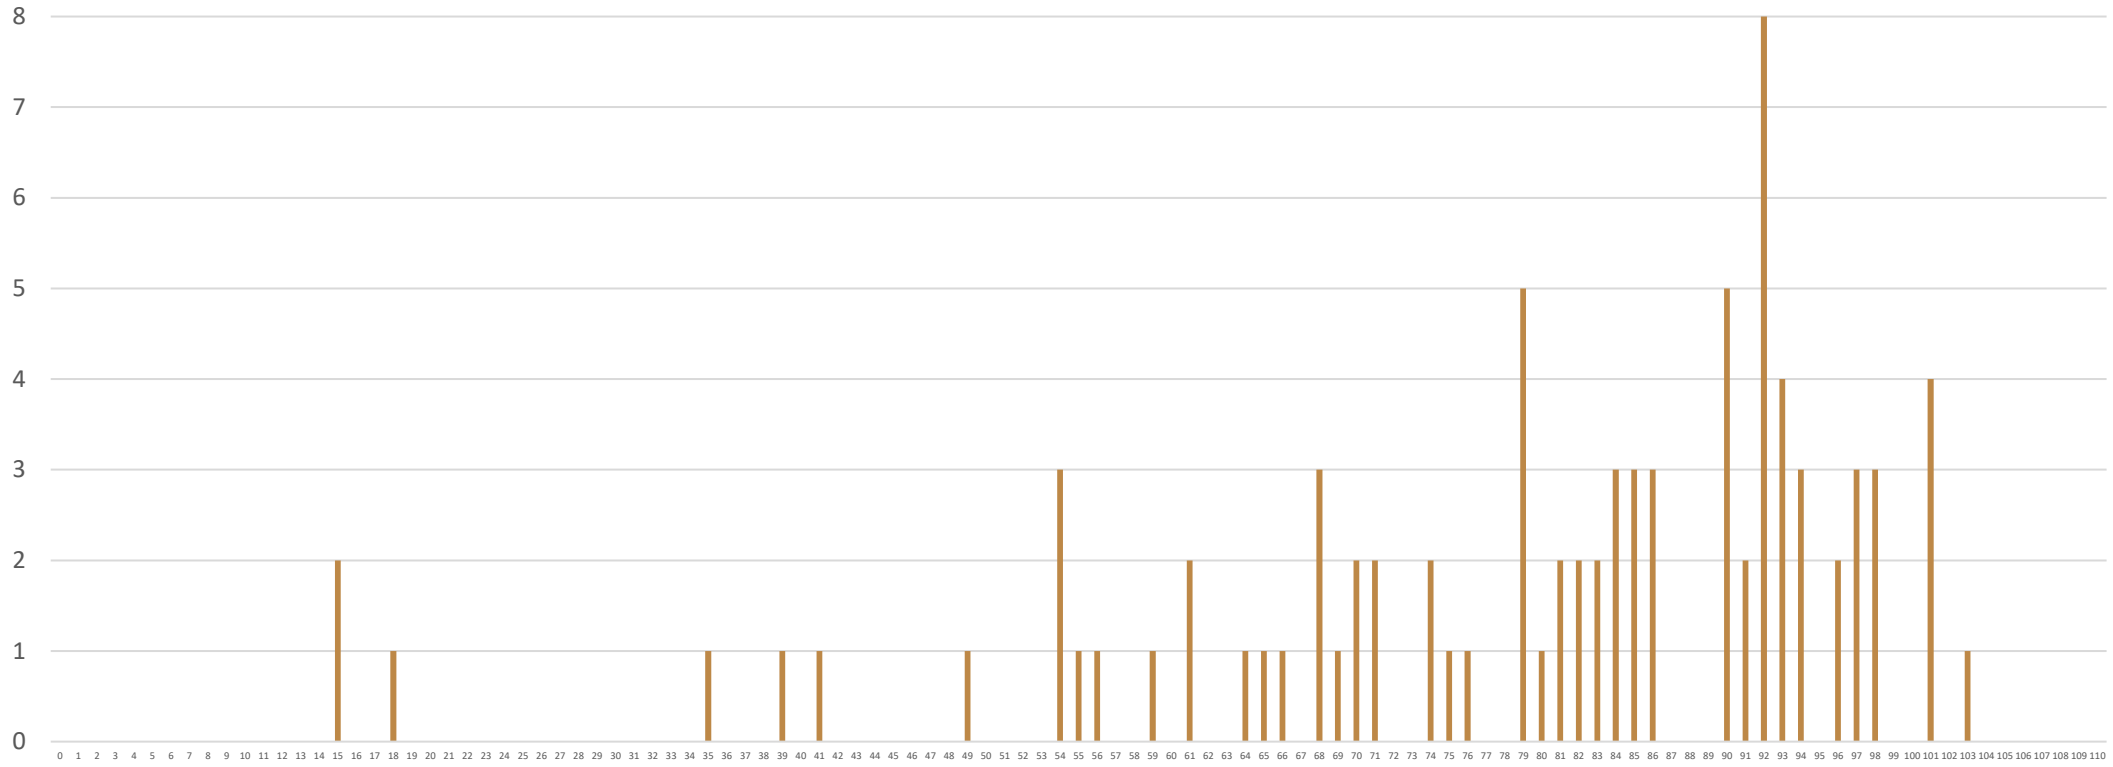


- 2024-ben 17 732 válás volt.
- Ennek kb. 83,3%-ában, azaz 14 771 esetben ez a férj első válása volt.
- A válások kb. 97,8%-a (17 339 eset) legfeljebb második válása volt a férjnek.

Forrás: https://www.ksh.hu

Statisztika I pontszámok (2025-26. tanév, GI szak)

Pontszám	f_i
0	0
1	0
2	0
3	0
4	0
5	0
6	0
7	0
8	0
9	0
10	0
11	0
12	0
13	0
14	0
15	2
16	0
17	0
18	1
19	0
20	0
21	0
22	0
23	0
24	0
25	0



- mind a táblázat, mind a diagram semmitmondó
- megoldás: pontszámok összevonása

GYAKORISÁGI SOR - Folytonos ismérv, vagy sok változatú diszkrét ismérv

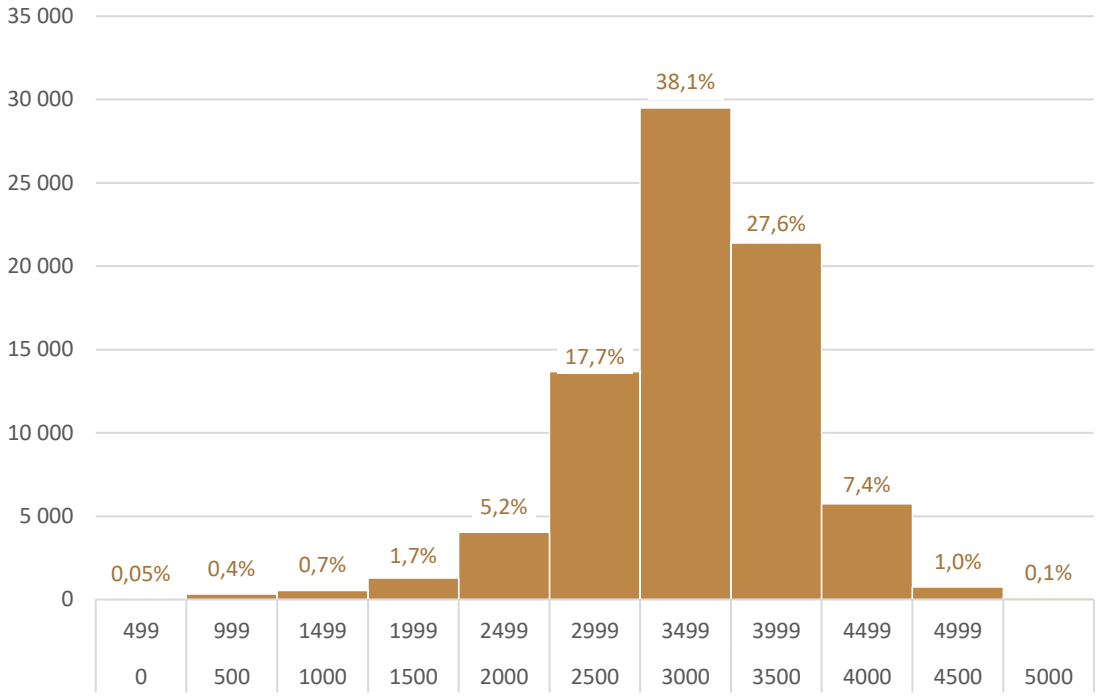
Ismérvváltozat	Gyakoriság	Osztályközép
Y_{10} - Y_{11}	f_1	Y_1
Y_{20} - Y_{21}	f_2	Y_2
...	...	...
Y_{i0} - Y_{i1}	f_i	Y_i
...	...	...
Y_{k0} - Y_{k1}	f_k	Y_k
Összesen	N	

$$\leftarrow Y_i = \frac{Y_{i0} + Y_{i1}}{2}$$

- Elnevezés: osztályközös gyakorisági sor

Élveszületések száma a születési súly szerint (2024)

Súly (g)		f_i	g_i	f'_i	g'_i
0	499	37	0,05%	37	0,05%
500	999	334	0,4%	371	0,5%
1000	1499	534	0,7%	905	1,2%
1500	1999	1 280	1,7%	2 185	2,8%
2000	2499	4 036	5,2%	6 221	8,0%
2500	2999	13 667	17,7%	19 888	25,7%
3000	3499	29 499	38,1%	49 387	63,8%
3500	3999	21 392	27,6%	70 779	91,5%
4000	4499	5 739	7,4%	76 518	98,9%
4500	4999	754	1,0%	77 272	99,9%
5000		99	0,1%	77 371	100,0%
Összesen		**77 371**	**100%**	**---**	**---**

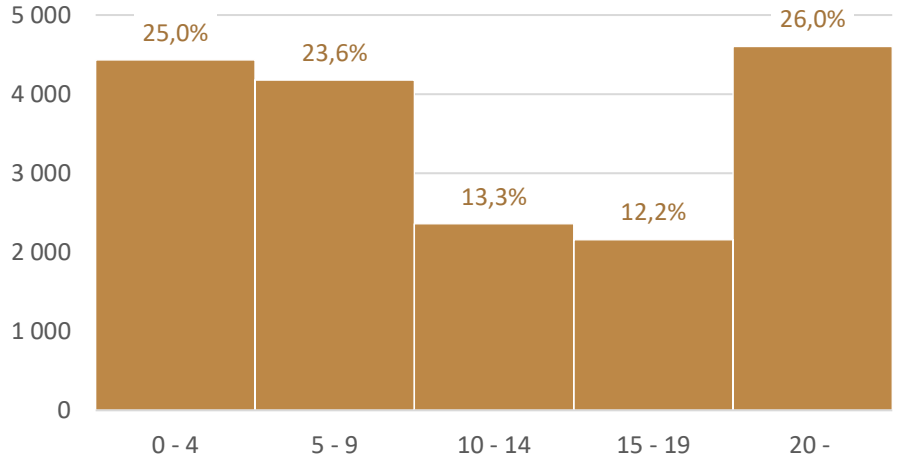


- sok ismérvváltozat → osztályközös gyakorisági sor és hisztogram
- 2024-ben 2 és 2,5 kg közötti súllyal 4 036 gyerek született, ami az élveszületések 5,2%-a. 3 kg alatti súllyal született a gyerekek kb. 25,7%-a, konkrétan 19 888 csecsemő.

Forrás: https://www.ksh.hu

Válások száma a házasság időtartama szerint (2024)

Házasságtartam		f_i	g_i	f'_i	g'_i
0	4	4 432	25,0%	4 432	25,0%
5	9	4 179	23,6%	8 611	48,6%
10	14	2 359	13,3%	10 970	61,9%
15	19	2 159	12,2%	13 129	74,0%
20		4 603	26,0%	17 732	100,0%
Összesen		**17 732**	**100%**	**---**	**---**



- sok ismérvváltozat → osztályközös gyakorisági sor és hisztogram
- DE! újra „semmitmondó”

Forrás: https://www.ksh.hu

BUDAPESTI CORVINUS EGYETEM
STATISZTIKA TANSZÉK

Osztályközök

- Osztályközök: egymást át nem fedő intervallumok
  - i. osztályközbe tartozó értékek: $Y_{i0} \leq Y \leq Y_{i1}$
  - az osztályköz felső határa folytonos esetben egybeesik a következő osztályköz alsó határával, ilyenkor a felső határoknál értünk határozott egyenlőtlenséget
  - Y_{10} és Y_{k1} megadása nem kötelező
    - ha szükséges, a mellette lévő osztályköz osztályhossza alapján adjuk meg
- Osztályközök száma
  - osztályok irányadó száma (Sturges-szabály): a legkisebb k, hogy $2^k \geq N$
    - az osztályközök száma ne haladja meg ezt
    - 15-20 osztályköznél többet nem érdemes használni (5-15 jó)

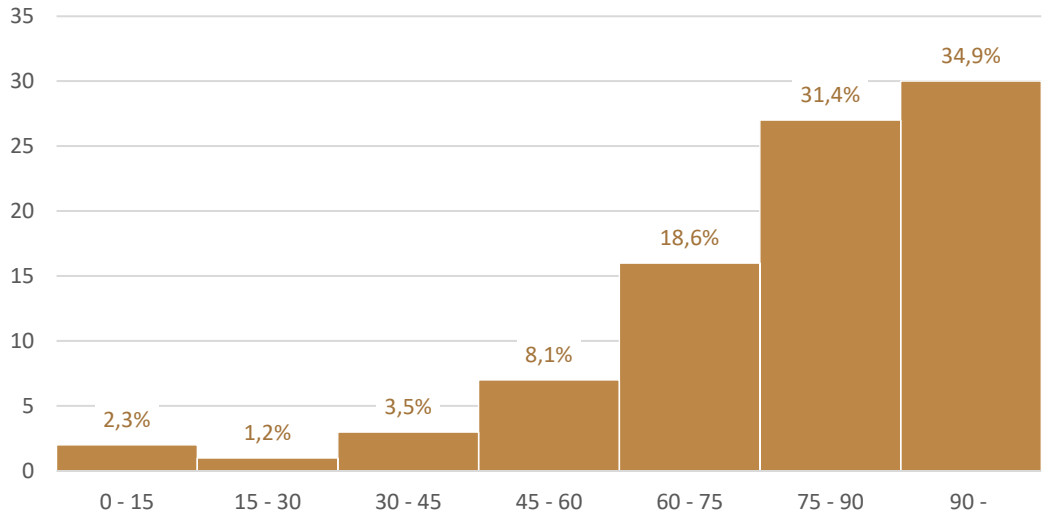


az osztályközök irányadó száma az előző feladatokban:

- Statisztika I pontok: 86 egyed → irányadó szám: 7 (helyette 111 ismérvváltozat ✗)
- születések hossza: 77371 egyed → irányadó szám: 17 (helyette 11 kategória ✓)
- válások száma: 17732 egyed → irányadó szám: 15 (helyette 5 kategória ✗)

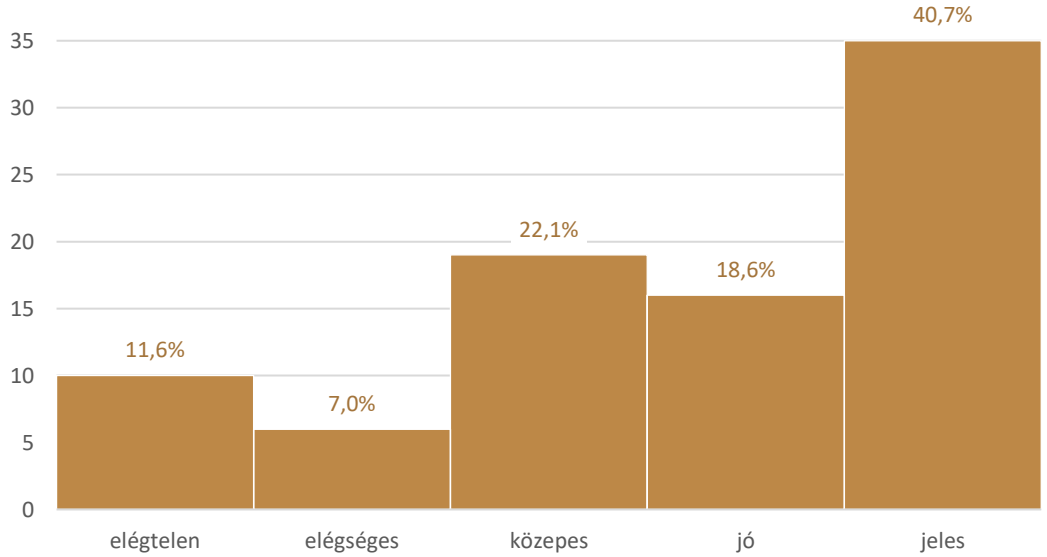
Statisztika I pontszámok (2025-26. tanév, GI szak)

Pontszám		f_i	g_i	f'_i	g'_i
0	15	2	2,3%	2	2,3%
15	30	1	1,2%	3	3,5%
30	45	3	3,5%	6	7,0%
45	60	7	8,1%	13	15,1%
60	75	16	18,6%	29	33,7%
75	90	27	31,4%	56	65,1%
90		30	34,9%	86	100,0%
Összesen		**86**	**100%**	**---**	**---**



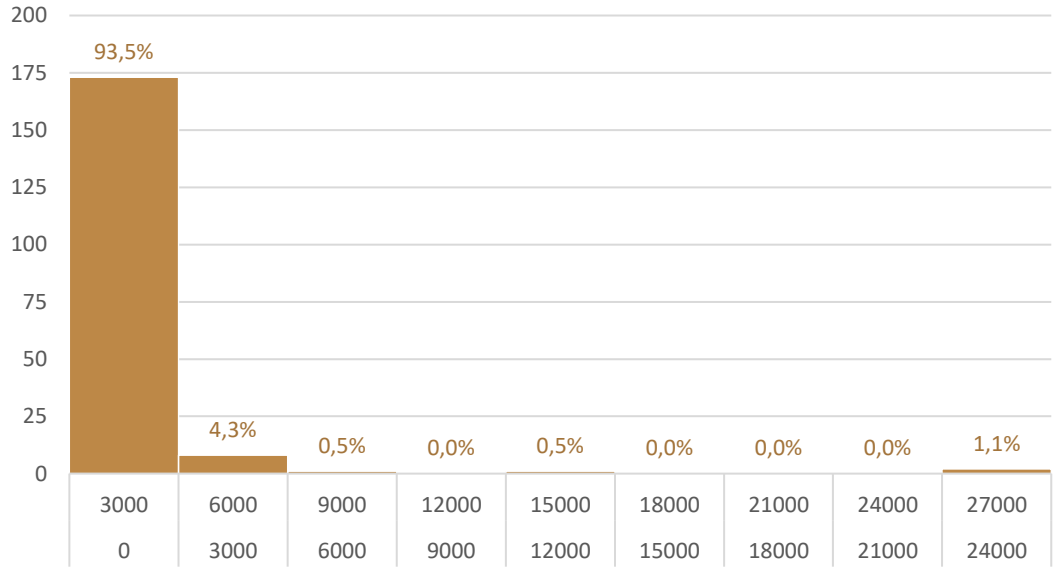
az osztályközök hossza lehet eltérő is:

Pontszám		f_i	g_i	f'_i	g'_i
0	54	10	11,6%	10	11,6%
55	64	6	7,0%	16	18,6%
65	79	19	22,1%	35	40,7%
80	89	16	18,6%	51	59,3%
90		35	40,7%	86	100,0%
Összesen		**86**	**100%**	**---**	**---**



A világ országainak GDP-je (2022, milliárd dollár)

GDP (Mrd $)		f_i	g_i	f'_i	g'_i
0	3000	173	93,5%	173	93,5%
3000	6000	8	4,3%	181	97,8%
6000	9000	1	0,5%	182	98,4%
9000	12000	0	0,0%	182	98,4%
12000	15000	1	0,5%	183	98,9%
15000	18000	0	0,0%	183	98,9%
18000	21000	0	0,0%	183	98,9%
21000	24000	0	0,0%	183	98,9%
24000	27000	2	1,1%	185	100,0%
Összesen		**185**	**100%**	**---**	**---**



- egyenetlen eloszlás → az egyenletes osztályköz használata miatt megint semmitmondó az eredmény

Forrás: https://www.ourworldindata.org

Osztályközök kialakítása

- Osztályközök kialakításának módjai:
  - egyenlő osztályközhossz: $h_0 = \frac{Y_{max} - Y_{min}}{k_0}$
  - konvención alapuló (pl. tízes számrendszer)
  - egyenlő gyakoriság (ld. kvantilis később)

ÉRTÉKÖSSZEGSOROK

- A gyakorisági táblázat alapján becslés adható az értékek összegére az osztályközép és a gyakoriság szorzataként:

  $\tilde{S}_i = f_i \cdot Y_i \quad \rightarrow$ becsült értékösszeg

- (Tényleges) értékösszeg: $S_i = \sum_{Y_{i0} \le Y \le Y_{i1}} Y$

  $\rightarrow$ relatív értékösszeg (Z_i), becsült relatív értékösszeg ($\tilde{Z}_i$)

  $\rightarrow$ kumulált értékösszeg-ek (S_i', $\tilde{S}_i'$)

  $\rightarrow$ kumulált relatív értékösszeg-ek (Z_i', $\tilde{Z}_i'$)

Határozzuk meg, hogy 50 km^2-nyi területenként vett osztályokba hány magyar város esik (2024)!

Helység	Terület (km^2)
Aba	88
Abádszalók	132
Abaújszántó	47
Abony	128
Ács	104
Adony	61
Ajak	25
Ajka	95
Albertirsa	73
Alsózsolca	26
Aszód	16
Bábolna	34
Bácsalmás	108
Badacsonytomaj	33
Baja	178
Baktalórántháza	35
Balassagyarmat	23
Balatonalmádi	50
Balatonboglár	32
Balatonföldvár	15
Balatonfüred	46

Osztályköz		Gyakoriság	Kumulált gyakoriság	Relatív gyakoriság	Kumulált r. gyakoriság
0	50	139	139	39,94%	39,94%
50	100	110	249	31,61%	71,55%
100	150	50	299	14,37%	85,92%
150	200	20	319	5,75%	91,67%
200	250	15	334	4,31%	95,98%
250	300	6	340	1,72%	97,70%
300	350	2	342	0,57%	98,28%
350	400	3	345	0,86%	99,14%
400	450	0	345	0,00%	99,14%
450		3	348	0,86%	100,00%
Összesen		**348**	**---**	**100,00%**	**---**

- Értelmezések:
  - 15 olyan város volt Magyarországon 2024-ben, amelyiknek a területe 200 és 250 km^2 közötti. Ez az összes város 4,31%-a.
  - 250 km^2-nél nem nagyobb területű a városok közel 96%-a. Konkrétan 334 város ilyen a 348 városból.

Forrás: https://www.ksh.hu

Határozzuk meg, hogy az egyes kategóriákba eső városok összesen hány km² területet foglalnak el!

Osztályköz		Osztály-közép	Becsült értékösszeg	Értékösszeg	Kumulált értékösszeg	Relatív értékösszeg	Kumulált r. értékösszeg
0	50	25	3 475	4 323	4 323	15,25%	15,25%
50	100	75	8 250	7 794	12 117	27,49%	42,73%
100	150	125	6 250	6 102	18 219	21,52%	64,25%
150	200	175	3 500	3 443	21 662	12,14%	76,39%
200	250	225	3 375	3 358	25 019	11,84%	88,23%
250	300	275	1 650	1 617	26 636	5,70%	93,94%
300	350	325	650	627	27 263	2,21%	96,15%
350	400	375	1 125	1 093	28 356	3,85%	100,00%
400	450	425	0	0	28 356	0,00%	100,00%
450		225	675	0	28 356	0,00%	100,00%
Összesen		---	28 950	28 356	---	100,0%	---

Értelmezések:

- A városok összterülete 28 356 km² (a becsült érték ugyanerre 28 950).
- Azok a városok, amelyeknek a területe 200 és 250 km² közötti, összességében 3 358 km² hektár területet foglalnak el, ami a városok által elfoglalt terület 11,84%-a.
  - egy ilyen kategóriájú város területe tehát átlagosan 223,9 km² (3 358 / 15)
- A 250 km²-nél nem nagyobb területű városok a városok összterületének 88,23%-át foglalják el, mégpedig 25 019 km²-t.

… folytatás (városok) …

Osztályköz		Gyakoriság	Kumulált r. gyakoriság	Kumulált r. értékösszeg
0	50	139	39,94%	15,25%
50	100	110	71,55%	42,73%
100	150	50	85,92%	64,25%
150	200	20	91,67%	76,39%
200	250	15	95,98%	88,23%
250	300	6	97,70%	93,94%
300	350	2	98,28%	96,15%
350	400	3	99,14%	100,00%
400	450	0	99,14%	100,00%
450		3	100,00%	100,00%
Összesen		348	---	---

- Problémafelvetések:
  - mit mutat a második osztályközhöz tartozó két kumulált érték eltérése?
  - az első 5 osztályba tartozik a városok közel 96%-a → mi értelme van a további osztályközöknek?
    - az egyenletes osztályközök kialakítása nem szerencsés

4. KVANTILISEK

– Hogy bírtad a lépcsőzést felfelé?
– A tüdőkapacitásom az alsó decilisénél van: a harmadik emeletre felértem, de a túléléshez szükséges oxigén 90 százaléka még valahol a földszinten maradt.

- Kvantilis: a rangsorba rendezett sokaságot egyenlő gyakoriságú részekre osztó osztályközhatár
  - k számú osztályközhöz k-1 osztópont kell → elnevezés: k-ad rendű kvantilisek
  - $Y_{i/k}$ az az érték, amelynél az összes előforduló érték i/k-ad része kisebb, (1-i/k)-ad része pedig nagyobb
    - az i/k érték megadható százalékos formában is; gyakran p-vel jelöljük
    - például $Y_{2/5} = Y_{0,4}$ az az érték, aminél az ismérv-értékek 40%-a kisebb, 60%-a nagyobb

Nevezetes kvantilisek

k	Elnevezés	Jelölés	Kvantilisek	Excel függvény
2	medián	Me	Me	MEDIÁN
4	kvartilis	Q_i	Q_1, Q_2, Q_3	KVARTILIS.KIZÁR
5	kvintilis	K_i	K_1, K_2, K_3, K_4	---
10	decilis	D_i	$D_1, D_2, \ldots, D_9$	---
100	percentilis	P_i	$P_1, P_2, \ldots, P_{99}$	PERCENTILIS.KIZÁR

- Pl. $Me = Q_2 = P_{50} = Y_{0,5}$
- Excel: $K_2 = Y_{0,4} = P_{40} \rightarrow$ PERCENTILIS.KIZÁR
- mennyi az 1; 5; 3; 4; 6; 10 adatsor mediánjának értéke?
  - válasz: 4,5

BUDAPESTI CORVINUS EGYETEM
STATISZTIKA TANSZÉK

Kvantilisek meghatározása egyedi értékekre

- Rangsorból (Y^*)
- Az $Y_{i/k}$ kvantilis sorszáma: $$s_{i/k} = \frac{i}{k} \cdot (N+1)$$
  - ha nem egész szám, akkor az arányos értéket kell meghatározni (lineáris interpoláció)
    - pl. $s = 5{,}4 \rightarrow Y^*_5 + 0{,}4 \cdot (Y^*_6 - Y^*_5)$
- Ha sok azonos érték van, nem jól használhatók!

TESZT: A02 – Kvantilisek meghatározása

3. kérdés

A hét törpe magassága (cm): 124, 141, 110, 115, 136, 106, 146
Mekkora a magasság alsó kvartilise?
+ Mekkora a 2. kvintilis?

- Az elemek sorrendben: 106, 110, 115, 124, 136, 141, 146
- $s_{1/4} = \frac{1}{4} \cdot (7+1) = 2 \quad \rightarrow Q_1 = 110$
- $s_{2/5} = \frac{2}{5} \cdot (7+1) = 3{,}2 \quad \rightarrow Y_{2/5} = 115 + 0{,}2 \cdot (124-115) = 116{,}8$

Kvantilisek meghatározása osztályközös gyakoriságiból

- A kvantilis osztályának meghatározása a kumulált sor alapján történik → q a legelső osztályköz sorszáma, melyre a kumulált relatív gyakoriság értéke meghaladja a kvantilis sorszámát
  - a sorszám esetén a +1 korrekciótól eltekinthetünk → $f'_q \geq \frac{i}{k} \cdot N$
- Kvantilis becsült értéke: alsó osztályhatár + az intervallum arányos terjedelme
  - arány: a kvantilis alattiak aránya az osztályközben

$$\tilde{Y}_{i/k} = Y_{q0} + h_q \cdot \frac{\frac{i}{k} \cdot N - f'_{q-1}}{f_q}$$

  - megkapható a kumulált relatív gyakoriságiból is:

$$\tilde{Y}_{i/k} = Y_{q0} + h_q \cdot \frac{\frac{i}{k} - g'_{q-1}}{g_q}$$

Az alábbi gyakorisági sor alapján határozzuk meg a felső kvartilis és a 3. kvintilis becsült értékét!

Kezdőérték	Végérték	f_i	f'_i	g_i	g'_i
0	1000	6	6	10%	10%
1000	2000	12	18	20%	30%
2000	3000	24	42	40%	70%
3000	4000	15	57	25%	95%
4000	5000	3	60	5%	100%
Összesen		60	---	100%	---

- Felső kvartilis
  - i/k = 3/4 $\rightarrow$ 3/4 · 60 = 45 $\rightarrow$ ez az érték a 4. osztályközben van (f'_i)
  - $Q_3 = 3000 + 1000 \cdot \frac{45-42}{57-42} = 3000 + 1000 \cdot \frac{3}{15} = 3200$
- 3. kvintilis (gyakoriságokból, illetve a relatív gyakoriságokból)
  - 3/5 · 60 = 36 $\rightarrow$ 3. osztályköz $\rightarrow K_3 = 2000 + 1000 \cdot \frac{36-18}{42-18} = 2750$
  - 3/5 = 0,6 = 60% $\rightarrow K_3 = 2000 + 1000 \cdot \frac{60\%-30\%}{70\%-30\%} = 2750$

A magyarországi városok területét vizsgáljuk egyenlő gyakoriságú osztályközök segítségével!

- Technikai megvalósítás:
  - a PERCENTILIS.KIZÁR függvénnyel a kvantilisek meghatározása (osztályköz felső határa)
    - az irányadó számként meghatározott 9 kategória ($2^9 > 348$) helyett a konvenciók miatt inkább deciliseket számolunk
      - az előző osztályközös gyakorisági sorból becsült első decilis értéke kb. $D_1 = 0 + 50 \cdot \frac{10\%}{39{,}94\%} \approx 12{,}5$
  - az értékösszeg meghatározása a SZUMHATÖBB függvénnyel

Osztályköz		Gyakoriság	Kumulált r. gyakoriság	Kumulált r. értékösszeg
0	24	34	9,8%	1,8%
24	33	35	19,8%	5,0%
33	39	35	29,9%	9,2%
39	51	35	39,9%	14,5%
51	62	35	50,00%	21,01%
62	76	35	60,1%	29,0%
76	96	35	70,1%	39,0%
96	126	35	80,2%	51,9%
126	179	35	90,2%	69,5%
179	525	34	100,0%	100,0%
Összesen		348		

- Az első decilis tényleges értéke kb. 24 km^2 (a becslés a nagyfokú aszimmetria miatt lett rossz)
- A városok első (legkisebb) feléhez a terület mindössze 21%-a tartozik.

BUDAPESTI CORVINUS EGYETEM
STATISZTIKA TANSZÉK

5.1. MENNYISÉGI SOROK ÁBRÁZOLÁSA

- Oszlopdiagram
  - kevésféle értéket felvevő ismérv esetén pálcika-diagram
  - osztályközös gyakorisági sor esetén hisztogram
- Vonaldiagram
  - gyakorisági poligon
  - folytonos határeset: gyakorisági görbe
  - kumulált sor: ogiva
- Leveles ág ábra (stem-and-leaf)
- Doboz ábra (boxplot, box-and-whiskers)

BUDAPESTI CORVINUS EGYETEM
STATISZTIKA TANSZÉK

Leveles ág (stem-and-leaf)

- A legnagyobb nagyságrendű érték a vonaltól balra, a jobbra lévő értékek a nagyságrendet pontosítják
  → kirajzolódik a gyakorisági sor képe, miközben az adatok is ismertek maradnak
- 🤔 például a 2026-os gazdinfós felvételi pontszámok leveles ág ábrája:

40	8
41	2 5
42	0 0 0 4 4 5 6 7 7 8 8 9 9
43	0 0 1 1 4 4 4 5 5 5 6 6 6 7 7 8 8 8 9
44	0 0 1 1 1 2 4 4 5 5 7 7 7 7 8 8 8 9 9 9
45	0 0 1 2 2 2 2 2 5 5 5 5 6 6 6 6 8 8
46	0 0 2 4 4 4 5 6 6 7 8 9
47	0 0 0 1 2 2 2 2 2 4 5 6 6 7 8
48	0 0 1 2 3 5 6 7
49	2 2

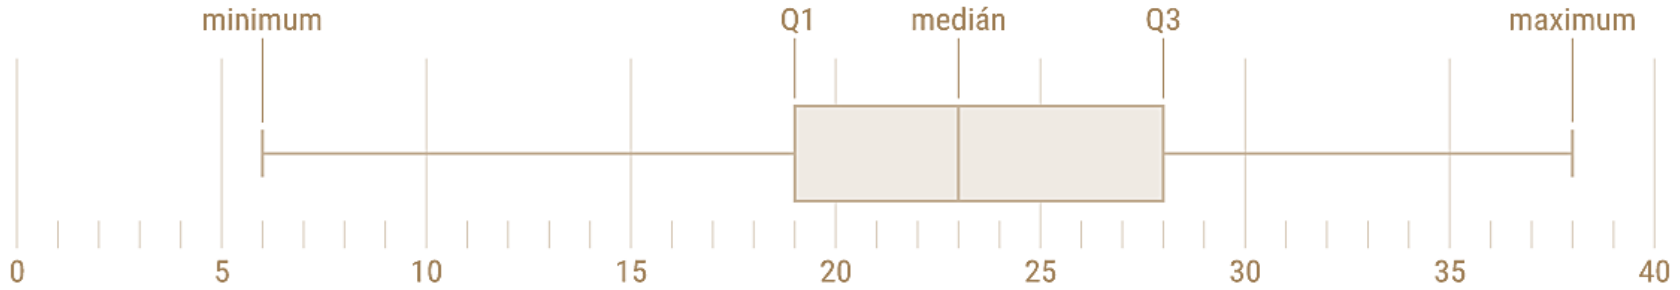
Dobozábra (5 pontos)

– Hogy bírod a mostani gazdasági helyzetet?

– Mint az alsó kvartilis: még épp nem vagyok a legrosszabb helyzetben, de a doboz tetejét már csak alulról nézem...

- Az x vagy az y tengelyen megjelölve a következő értékek:
  - legkisebb érték
  - alsó kvartilis
  - medián
  - felső kvartilis
  - legnagyobb érték
- dobozba zárva az összes érték középső fele
  → melyik szélhez esik közelebb
  → milyen terjedelmű

🤔 a 6, 18, 19, 20, 21, 23, 25, 27, 28, 32, 38 adatsor (vízszintes) dobozábrája:



Dobozábra (7 pontos)

- 5 pontos ábra kibővítve (boxplot, box-and-whiskers):
  - a két szélső kvartilis távolsága másfélszeresének meghatározása (Tukey-elv)
  - alsó kerítés: felmérés az alsó kvartilistől lefelé
  - felső kerítés: felmérés a felső kvartilistől felfelé
  - ha a kerítések felett vannak értékek, azok pontként szerepelnek (kilógó értékek)
    - ha nincs ilyen, akkor a minimumot / maximumot jeleníti meg



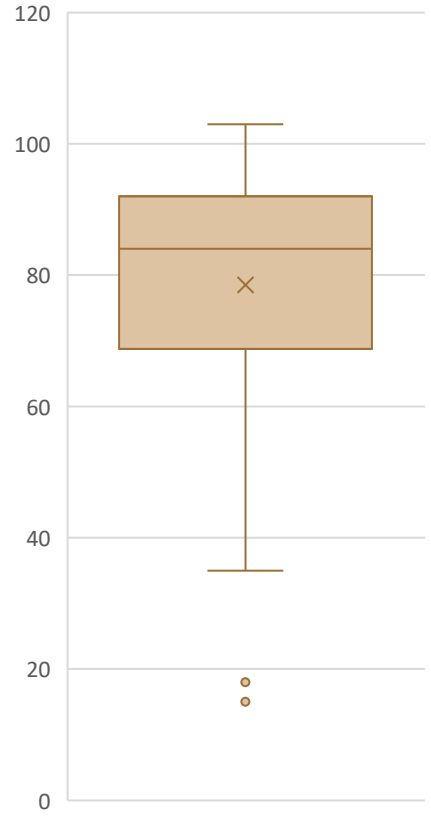
a 2025/2026. GI Stat I pontok 7 pontos dobozábrája:

$\rightarrow$ Min = 15, $Q_1 \approx 69$, Me = 84, Q_3 = 92, Max = 103

$\rightarrow$ alsó kerítés = 69 - 1,5·23 = 34,5
felső kerítés = 92 + 1,5·23 = 126,5

– Mi ez a furcsa stílus? A bajszod bal szára a füledig ér, a jobb meg alig látszik.

– Ez nem stílus, ez módszertan. Így szemléltetem a diákoknak a negatív ferdeséget anélkül, hogy ki kéne vetítenem egy grafikont.



Hisztogram és gyakorisági poligon

- Hisztogram: osztályközös gyakorisági sor esetén
  - hézagmentes, az oszlopok területe arányos a gyakoriságokkal
  - többféle osztályközhosszúság esetén f_i/h_i ábrázolása
- 🤔 a pontszámok hisztogramja és gyakorisági poligonja egyenletes osztályközök esetén, illetve hisztogram nem egyenletes, jegyek szerinti osztályközöknél:

